

Caderno Metodológico

Etapas de Modelagem e Avaliação em Massa

Luiz Fernando Palin Droubi

julho, 2026

Índice

Apresentação	4
1 Introdução	5
2 Metodologia Geral	6
3 Limpeza de dados	7
3.1 Métodos de limpeza de dados	7
3.1.1 <i>Breakdown point</i>	9
3.1.2 Mínimos Quadrados Ordinários	10
3.1.3 <i>M-Estimadores</i>	11
3.1.4 Mínimos Quadrados Aparados	12
3.1.5 <i>MM-estimadores</i>	14
4 Métodos de classificação	16
4.1 <i>K-means</i>	16
4.2 <i>K-TAU</i>	16
4.3 <i>K-medoids</i>	19
5 Geração de variáveis explicativas	20
5.1 Renda Krigada	20
5.1.1 Metodologia	20
5.1.2 Construção da área de interpolação	21
5.1.3 Ajuste do semivariograma	22
5.1.4 Execução da krigagem no SAGA GIS	22
5.1.5 Extração dos valores krigados para os imóveis	23
5.1.6 Resultados	24
5.1.6.1 Parâmetros finais dos semivariogramas	24
5.1.6.2 Ajustes dos semivariogramas	24
5.1.7 Síntese dos resultados	40
5.2 Valor Unitário do metro quadrado edificado	41
5.2.1 Modelo Linear	41
5.2.2 Geração da superfície de valores unitários de metro quadrado construído	41
5.3 Clusters de localização	43
5.4 Variáveis de localização – Acessibilidade e Centralidade	44
5.4.1 Acessibilidade (Ace)	44

5.4.2	Centralidade (Cen)	45
6	Análise de dados com modelos de aprendizado de máquina	47
7	Análise de dados de lotes urbanos	48
7.1	Modelo Linear Hierárquico (MLH)	48
7.2	Homogeneização	52
7.3	Geração da superfície de valores unitários de lotes	52
7.4	Modelo final	52
8	Equações de Estimação	53
9	Equações de Estimação	54
10	Classificação de Municípios	55
11	Conclusão	56
	Referências	57
	Apêndices	60
A	Apêndice 1: Scripts	60

Apresentação

Trata-se de um caderno metodológico para o projeto do Valor de Referência do Cadastro Imobiliário Brasileiro (CIB)

1 Introdução

Neste caderno ...

2 Metodologia Geral

Para o projeto do Valor de Referência (VR) do Cadastro Imobiliário Brasileiro (CIB) foi adotado o **Método Evolutivo**, da Equação 2.1, método consagrado que estima o valor de mercado de um imóvel através da soma dos seus componentes (terra e capital aplicado):

$$V_{\text{Imóvel}} = (V_{\text{Terreno}} + V_{\text{Benfeitorias}}) \cdot FC \quad (2.1)$$

Em que:

- $V_{\text{Imóvel}}$ é o valor de mercado do imóvel acabado;
- V_{Terreno} é o valor de mercado do lote sobre o qual o imóvel encontra-se edificado;
- $V_{\text{Benfeitorias}}$ é o valor do capital aplicado em benfeitorias no imóvel e;
- FC é um “fator de comercialização” empregado para ajustar a diferença entre o valor real de mercado do imóvel e a diferença entre a soma dos seus componentes.

Os valores de benfeitorias são calculados através dos custos de construção divulgados pelos SINDUSCON locais. Os valores dos terrenos, por outro lado, devem ser estimados via modelos lineares, geoestatística ou algoritmos preditivos de aprendizado de máquina. Para o fator de comercialização, o ideal é que este seja inferido através de dados de mercado de imóveis edificados.

Neste projeto procura-se extrair o máximo de informação de todo o conjunto de dados de mercado, que envolvem anúncios não apenas de lotes, mas também de imóveis edificados, como casas, apartamentos e outros, tanto de venda quanto de locação.

SILVA et al. (2024)

3 Limpeza de dados

A Etapa de Modelagem e Avaliações em Massa é iniciada com a limpeza dos dados oriundos do Observatório do Mercado Imobiliário. Neste capítulo são apresentados os métodos utilizados.

3.1 Métodos de limpeza de dados

A limpeza de um conjunto de dados para fins de posterior ajuste de modelos estatísticas pode ser feita com a utilização de diversos métodos. São bem difundidos especialmente os métodos univariados de identificação de *outliers*, como o clássico método de *Chauvenet*, que presume a presença de distribuição normal. Outros métodos univariados, por outro lado, são preferíveis pois prescindem da verificação da hipótese da normalidade e também são considerados mais robustos, como o método do *boxplot*, que classifica como *outliers* aqueles pontos que se encontram a uma distância de $1,5 \cdot \text{IQR}$ dos primeiro e terceiro quartis (Q_1 e Q_3)¹. A Figura 3.1 ilustra graficamente o critério do *boxplot* para identificação de *outliers*:

Neste projeto, porém, optou-se pela utilização de métodos multivariados para a limpeza dos conjuntos de dados, tal como o método dos mínimos quadrados aparados. Tal método foi escolhido com o intuito de evitar a remoção desnecessária de muitos falsos *outliers* da amostra. Para entender, considere-se os *bagplots* (ou diagramas de saco) das Figuras 3.2 e 3.3².

Na Figura 3.2 podem ser vistos os diagramas de caixa de cada variável, às margens do gráfico principal, em que é possível notar uma assimetria na amostra: existe uma série de pontos à direita da distribuição de ambas as variáveis classificados como *outliers* pelo critério do *boxplot* ($Q_3 + 1,5 \cdot \text{IQR}$). O gráfico *bagplot* da Figura 3.2, no entanto, em que 50% dos dados se encontram dentro do primeiro *bag*, de cor mais escura, e cuja área que separa os *outliers* dos *inliers* é exibida em cor cinza-clara, mostra que apenas 4 pontos foram classificados como *outliers*. Note-se ainda que dois dos pontos classificados como *outliers* pelo critério do *bagplot* não foram identificados pelo critério do *boxplot*.

Já na Figura 3.3, em que as variáveis explicativas apresentam distribuição mais simétrica, pois as variáveis encontram-se transformadas para a obtenção da normalidade, pode-se notar que o critério dos *boxplots* implicaria remover uma série de pontos em ambos os lados da distribuição

¹Lembrando que IQR é a medida de dispersão denominada de intervalo interquartil, *i.e.* $\text{IQR} = Q_3 - Q_1$.

²O *bagplot* é uma generalização do *boxplot* para duas dimensões, proposto por ROUSSEEUW et al. (1999), baseado nos conceitos de Profundidade de Tukey, ou Profundidade do meio-espaco e na mediana profunda, ou mediana bivariada (TUKEY, 1975).




Figura 3.1: Boxplot.

das variáveis, enquanto o critério do *bagplot* mostra que, novamente, apenas alguns pontos precisam de fato ser removidos da amostra para uma boa modelagem.




Figura 3.2: Bagplot. Preços Totais

Os conceitos de profundidade estatística e mediana profunda podem ser estendidos para outras dimensões. O algoritmo para o cômputo eficiente destas estatísticas pode ser visto em STRUYF; ROUSSEEUW (2000).

O método dos mínimos quadrados aparados, como veremos na próxima seção, ajusta um modelo de regressão robusta a aproximadamente 50% dos pontos mais “importantes” da amostra, classificando como potenciais *outliers* os pontos que apresentam resíduos padronizados maiores, em módulo, a 2,5, calculados em relação ao modelo ajustado com esses dados mais “importantes”.

3.1.1 Breakdown point

Segundo DAVIES; GATHER (2007), uma das melhores medidas de robustez é o *breakdown point* (ϵ^*), conceito desenvolvido por HODGES (1967) e estendido por HAMPEL (1971) e DONOHO; HUBER (1983):

The breakdown point is one of the most popular measures of robustness of a statistical procedure. Originally introduced for location functionals (Hampel, 1968,




Figura 3.3: Bagplot. Preços Unitários.

1971) the concept has been generalized to scale, regression and — with more or less success — to other situations.

Grosso modo, o *breakdown point* de um estimador é o menor percentual de dados contaminantes que levam o estimador a assumir arbitrariamente grandes valores, ou valores aberrantes. Para compreender, tome-se o caso da estimação da tendência central, μ , de um conjunto de dados com distribuição supostamente normal. A média aritmética, $\bar{x}$, neste caso, é um estimador com $\epsilon^* = 0$, pois basta um dado amostral contaminante para produzir estimativas totalmente equivocadas para o parâmetro. No outro extremo encontra-se a mediana amostral, $\tilde{x}$, apresenta $\epsilon^* = 0,5$, ou seja, a mediana é um estimador robusto para o parâmetro central da distribuição, desde que menos de 50% dos dados amostrais sejam contaminantes.

3.1.2 Mínimos Quadrados Ordinários

Para melhor compreensão do método dos mínimos quadrados aparados, deve-se contextualizá-lo com o método clássico dos mínimos quadrados ordinários.

Seja então o modelo usual de regressão da Equação 3.1, em que $\mathbf{y}$ é um vetor que contém uma **variável dependente** a ser explicada; $\mathbf{X}$ uma matriz que contém em suas colunas uma ou mais **variáveis explicativas**; e β é um vetor de coeficientes a ser estimado.

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{r} \quad (3.1)$$

Então o método dos mínimos quadrados ordinários consiste na minimização de uma função objetivo, S , neste caso a função soma do quadrado dos resíduos, $S(\beta) = \sum r_i^2(\beta)$. Ou seja, no método dos mínimos quadrados ordinários busca-se minimizar:

$$\hat{\beta}_{\text{OLS}} = \min_{\beta} S(\beta) = \arg \min_{\beta} \sum_{i=1}^n r_i^2(\beta) \quad (3.2)$$

Em que $\mathbf{r}$ é um vetor dos resíduos do modelo da Equação 3.1, ou seja:

$$\mathbf{r} = \mathbf{y} - \mathbf{X}\beta \quad (3.3)$$

Assim, a Equação 3.2 poderia ser escrita, de uma maneira mais formal, em notação matricial, como abaixo:

$$= \arg \min_{\beta} \sum_{i=1}^n (\mathbf{y} - \mathbf{X}\beta)^2 \quad (3.4)$$

Deste ponto em diante, contudo, para fins de simplificação do entendimento, adota-se a seguinte notação, reescrevendo a Equação 3.2:

$$\hat{\beta}_{\text{OLS}} = \arg \min_{\beta} \sum_{i=1}^n r_i^2 \quad (3.5)$$

3.1.3 *M-Estimadores*

Os métodos robustos consistem em variações em torno do processo de minimização dos resíduos. Enquanto no método clássico dos mínimos quadrados ordinários é minimizada a soma do quadrado dos resíduos, no método dos mínimos resíduos absolutos, proposto por EDGEWORTH (1887), baseado no método gráfico de Boscovich, tem-se:

$$\hat{\beta}_{\text{LAD}} = \arg \min_{\beta} \sum_{i=1}^n |r_i| \quad (3.6)$$

Segundo ROUSSEEUW (1984), o próximo passo no progresso dos métodos de regressão robustos se deu com o surgimento dos *M-Estimadores*, baseados na ideia da aplicação de uma função, ρ , dos resíduos, diferente da função quadrática, como ilustrado na Equação 3.7.

$$\hat{\beta}_{\text{RLS}} = \arg \min_{\beta} \sum_{i=1}^n \rho(r_i) \quad (3.7)$$

É fácil perceber que a intenção com os *M-Estimadores* foi contornar o fato que a função absoluto, $|r(t)|$, não possui propriedades desejáveis (não é uma função derivável em $t = 0$, o que dificulta o processo de minimização). Assim, HUBER (1964) propôs inicialmente a aplicação da função da Equação 3.8, que consiste em utilizar, para os menores resíduos, em módulo ($|r_i| \leq k$), a função quadrática e, somente a partir de um valor k (ou seja, para $|r_i| > k$), a função absoluto.

$$\rho_{\text{Huber}}(t) = \begin{cases} \frac{1}{2}t^2 & |t| \leq k \\ k|t| - \frac{1}{2}k^2 & |t| > k \end{cases} \quad (3.8)$$

Diversas outras funções foram propostas para a Equação 3.7, como a função *biweight* de Tukey. No entanto, tanto no método dos mínimos desvios absolutos da Equação 3.6, quanto nos *M-Estimadores*, persiste à sensibilidade à presença de *outliers* nas variáveis explicativas, *i.e.*, os *M-Estimadores* são eficazes apenas em lidar com a presença de *outliers* na variável dependente (no caso, imóveis de valores observados muito mais altos ou mais baixos do que os que seria previstos pelo mercado). Desta forma, tanto o estimador MQO da Equação 3.2 como os *M-Estimadores* possuem *breakdown point* $\epsilon^* = 0$.

3.1.4 Mínimos Quadrados Aparados

Então ROUSSEEUW (1984), para contornar o problema dos *outliers* presentes nas variáveis explicativas, propôs dois estimadores robustos alternativos aos *M-Estimadores*: o estimador **LMS** (*Least Median of Squares*), que minimiza **a mediana** dos resíduos quadráticos (Equação 3.9), e o estimador LTS (*Least Trimmed Squares*, ou Mínimos Quadrados Aparados), que minimiza o quadrado dos resíduos, porém apenas para os “bons” pontos da amostra:

$$\beta_{\text{LMS}} = \arg \min_{\beta} \text{med } r_i^2 \quad (3.9)$$

$$\beta_{\text{LTS}} = \min_{\beta} \sum_{i=1}^h (r^2)_{(i)} \quad (3.10)$$

Em que $(r^2)_{(1)} < (r^2)_{(2)} < \dots < (r^2)_{(n)}$ são os resíduos quadráticos ordenados. Resumidamente: o estimador LTS da Equação 3.10 utiliza aproximadamente apenas h pontos da amostra (em geral, $h \approx n/2$) para um ajuste mais estável, e calcula os resíduos de cada ponto da amostra em relação à esta reta de regressão robusta. Após o cálculo dos resíduos os pontos são classificados

como “bons” (pontos cujos resíduos padronizados são menores que 2,5, em módulo) ou “ruins” (pontos cujos resíduos padronizados são maiores ou iguais a 2,5).

O estimador LTS é famoso por apresentar *breakdown point* igual a 50% (máximo)³, isto é, contanto que menos de metade dos pontos do conjunto de dados em análise consista de *outliers*, o algoritmo é eficaz em identificar esses pontos anômalos e ajustar um modelo que reflete o padrão verdadeiro dos dados.

Para ilustrar, o gráfico da Figura 3.4 mostra como a presença de *outliers*, especialmente aqueles dois pontos de maior e menor preço unitário, influenciam a estimação do coeficiente angular do modelo, mostrando um efeito maior (reta vermelha) do que o efeito “real” da variável área sobre os preços unitários (reta verde). Já a Figura 3.5 mostra que o ajuste da reta de regressão linear ordinária apenas aos pontos centrais (*i.e.*, sem a inclusão dos dois pontos extremos supramencionados), seria já suficiente para a obtenção de um modelo bem ajustado.




Figura 3.4

Neste caso, seria fácil estimar um modelo de regressão linear ordinária e identificar os dois pontos extremos e removê-los do modelo, obtendo assim um modelo já mais confiável. No entanto, o estimador LTS ainda classifica como *outliers* outros pontos da amostra, ilustrados em vermelho na Figura 3.6, melhorando assim o ajuste final do modelo.

É importante destacar que não se trata de um processo para exclusão automática de *outliers*, no entanto: a aplicação do algoritmo LTS não dispensa a análise dos pontos classificados

³Quando são utilizados para o ajuste do modelo apenas aproximadamente 50% dos dados, *i.e.*, quando $h = (n/2) + 1$.




Figura 3.5

como *outliers* pelo avaliador, que deve decidir se retira realmente todos os pontos *flagados* pelo algoritmo.

3.1.5 *MM-estimadores*

Os *MM-estimadores* foram primeiramente propostos por YOHAI (1987).

Assim como o estimador de mínimos quadrados aparados, os *MM-estimadores* podem apresentar o valor máximo para o *breakdown-point* (0,5), na condição em que os resíduos tenham distribuição normal (YOHAI, 1987).

Segundo YOHAI (1987), os *MM-estimadores* são obtidos em três estágios. No primeiro, um modelo de regressão robusta com alto *breakdown-point*, como o dos mínimos quadrados aparados, é estimado. Com o modelo obtido no primeiro estágio, então, são computados os resíduos e, com estes, por sua vez, um estimador robusto de escala dos resíduos é obtido.

Neste projeto, o objetivo com a utilização dos métodos robustos é a mera limpeza dos dados, o que possibilita a utilização de outros métodos a posteriori com mais segurança. Portanto, não foi adotada a utilização dos **MM-Estimadores**.




Figura 3.6

4 Métodos de classificação

Para este projeto foram utilizados métodos robustos de classificação (ou *clusterização*). Assim como no caso da regressão robusta, é mais fácil compreender os métodos de classificação robusta quando comparámo-los aos métodos clássicos de classificação, como o método *K-means*.

4.1 *K-means*

O método *K-means* é um método de *clusterização* de dados que consiste na minimização da distância quadrática entre os pontos da amostras e K centros $\mu_1, \mu_2, \dots, \mu_k$. Sejam as distâncias definidas conforme a Equação 4.1 abaixo

$$D(\mathbf{x}_i, \mu_1, \dots, \mu_K) = \min_{1 \leq i \leq K} \|\mathbf{x}_i - \mu_j\|, 1 \leq i, \leq k \quad (4.1)$$

Os centros dos clusters, dessa forma, são obtidos conforme a Equação 4.2:

$$(\hat{\mu}_1, \dots, \hat{\mu}_k) = \arg \min_{\mu_1, \dots, \mu_k} \sum_{i=1}^n D^2(\mathbf{x}_i, \mu_1, \dots, \mu_K) \quad (4.2)$$

O problema com o método *K-means* é que, a exemplo do que ocorre com o método dos mínimos quadrados ordinários, este método é muito sensível à presença de *outliers* (GONZALEZ et al., 2019, p. 2). A Figura 4.1 (A) mostra que o método é eficiente em estimar as k-médias, porém, na presença de *outliers* (Figura 4.1 (B)), os resultados ficam comprometidos.

4.2 *K-TAU*

Driver: GPKG

Available layers:

	layer_name	geometry_type	features	fields
1	face_logradouro	Multi Line String	20329	8
2	logradouro	Multi Line String	14261	8
3	municipio	Multi Polygon	1	15
4	regiao_geografica_imediata	Multi Polygon	1	11






Figura 4.1: Problema com *K-means*: sensibilidade à *outliers*. Fonte: GONZALEZ et al. (2019)

5	regiao_geografica_intermediaria	Multi Polygon	1	9
6	setor_censitario	Multi Polygon	1004	29
7	setor_censitario_urbano	Multi Polygon	930	29
8	subsetor_urbano	Multi Polygon	4360	1
9	uf	Multi Polygon	1	6
10	limite_perimetro_urbano	Multi Polygon	9	12
11	edificacao	Point	258267	6
12	amostra_omi	Point	83869	62
13	variavel_geografica_setor_censitario	Multi Polygon	1004	68
14	variavel_geografica_amostra_omi	Point	83600	121
15	layer_styles	NA	12	12
crs_name				
1	SIRGAS 2000			
2	SIRGAS 2000			
3	SIRGAS 2000			
4	SIRGAS 2000			
5	SIRGAS 2000			
6	SIRGAS 2000			
7	SIRGAS 2000			
8	SIRGAS 2000			
9	SIRGAS 2000			
10	SIRGAS 2000			
11	SIRGAS 2000			

```
12 SIRGAS 2000
13 SIRGAS 2000
14 SIRGAS 2000
15      <NA>
```

```
Reading layer `variavel_geografica_amostra_omi' from data source
  `/Users/droubi/Documents/LabFSG/Caderno_Metodologico/data/4205407_Florianopolis_r007_2026-
04-06.gpkg'
  using driver `GPKG'
Simple feature collection with 83600 features and 121 fields
Geometry type: POINT
Dimension:      XY
Bounding box:   xmin: -48.60608 ymin: -27.81767 xmax: -48.37625 ymax: -27.38705
Geodetic CRS:  SIRGAS 2000
```





GONZALEZ et al. (2019) propuseram

4.3 *K-medoids*

K-medoids é um método robusto de *clusterização* que

5 Geração de variáveis explicativas

Além da variável PC (*Padrão Construtivo*), obtida através de algoritmos de *clusterização*, conforme capítulo anterior, outras variáveis explicativas foram criadas visando a obtenção de um melhor ajuste para os modelos estatísticos, como a variável RPCSMK (*Renda per capita, em salários mínimos, krigada*) e VUM2 (*Valor Unitário do metro quadrado edificado*).

5.1 Renda Krigada

O processo de krigagem dos Lotes 1 e 2 teve como objetivo gerar superfícies interpoladas de renda média atribuída aos setores censitários para os municípios selecionados e associar os valores estimados dessas superfícies aos pontos dos imóveis/anúncios OMI.

A krigagem foi realizada a partir da variável geográfica `renda_med_pct`, descrita como **Renda média do familiar responsável pelo domicílio (por setor)**, posteriormente transformada em escala logarítmica para favorecer o ajuste geoestatístico. Após a geração das superfícies krigadas raster em GeoTIFF, os valores interpolados foram extraídos para os pontos dos imóveis, compondo o resultado consolidado `dna_estimacao_consolidado_renda_krigada` com a coluna final `renda_krigada_ln`.

O escopo final da consolidação considerou 8 municípios:

- Lote 1: belo_horizonte, campo_grande, fortaleza, porto_velho.
- Lote 2: cuiaba, curitiba, manaus, salvador.

5.1.1 Metodologia

O processo metodológico combinou etapas de preparação da base, ajuste geoestatístico, interpolação por krigagem ordinária local e extração dos valores interpolados para os pontos dos imóveis/anúncios OMI.

Foram utilizados os seguintes softwares e ferramentas:

- QGIS 3.44.10;
- plugin Smart-Map no QGIS;
- SAGA GIS 2.1.2.

O ajuste dos semivariogramas foi realizado no Smart-Map, no ambiente do QGIS 3.44.10. A interpolação foi executada no SAGA GIS 2.1.2, com inserção manual dos parâmetros previamente ajustados, sem reajuste do variograma no SAGA.

2.1. Base de entrada e preparação da variável

Em cada município, a estrutura geral de trabalho foi organizada nas seguintes pastas:

- **entrada:** camada dos centróides dos setores censitários dos municípios;
- **pontos_anuncios_OMI:** camada de pontos dos dados de imóveis do OMI;
- **projeto:** arquivos do QGIS, Smart-Map, centroides, buffer e projeto SAGA;
- **parametros:** imagens e registros auxiliares dos parâmetros usados no ajuste do semivariograma;
- **saida:** arquivos finais, incluindo os GeoTIFF das superfícies krigadas raster e as camadas vetoriais com a coluna resultante **renda_krigada_ln**, posteriormente consolidadas em **dna_estimacao_consolidado_renda_krigada**.

A base pontual utilizada no ajuste geoestatístico foi a camada de centroides dos setores censitários previamente disponível no acervo do projeto. Portanto, os centroides não foram gerados nesta etapa; eles foram utilizados como insumo já existente.

A preparação da base incluiu:

1. seleção da variável geográfica **renda_med_pct** (Renda média do familiar responsável pelo domicílio (por setor));
2. limpeza da base;
3. remoção de outliers;
4. remoção de valores nulos, iguais a zero ou negativos;
5. transformação logarítmica dos valores válidos de **renda_med_pct**.

A logaritimização foi aplicada para reduzir a assimetria da distribuição dos valores de **renda_med_pct** e favorecer melhor ajuste do semivariograma. Assim, a krigagem foi realizada sobre a variável logaritimizada, e não diretamente sobre os valores brutos de renda média.

5.1.2 Construção da área de interpolação

Com a base limpa e logaritimizada, foi utilizado o conjunto de pontos válidos dos centroides dos setores censitários.

A partir desses pontos, foi construído um envoltório convexo. Em seguida, foi gerado um buffer de 1.500 metros ao redor desse envoltório.

Esse buffer foi utilizado como máscara espacial para recortar a superfície krigada, delimitando a área de interpolação e evitando extrapolações excessivas para regiões afastadas da distribuição dos pontos de entrada.

As superfícies krigadas raster resultantes da krigagem foram exportadas no SAGA GIS em formato GeoTIFF. Esses arquivos serviram como base para o recorte espacial e para a extração posterior dos valores interpolados para os pontos dos imóveis/anúncios OMI.

5.1.3 Ajuste do semivariograma

O ajuste dos semivariogramas foi realizado no plugin Smart-Map, no QGIS.

Os parâmetros finais de cada município foram registrados na tabela oficial:

`documentacao_variogramas_krigagem\01_tabela_parametros\tabela_parametros_krigagem_final.csv`

Também foram preservados arquivos de imagem dos semivariogramas nas pastas municipais de `Lote_1` e `Lote_2`, especialmente nos diretórios `parametros`, que foram utilizados como evidência visual neste relatório.

Os parâmetros principais registrados foram:

- modelo de semivariograma;
- efeito pepita;
- patamar;
- alcance;
- distância máxima;
- lag.

5.1.4 Execução da krigagem no SAGA GIS

Após o ajuste no Smart-Map, os parâmetros do semivariograma foram inseridos manualmente no SAGA GIS 2.1.2.

A interpolação foi realizada por krigagem ordinária local.

A sequência operacional foi:

1. preparação da base de setores censitários e definição da variável geográfica `renda_med_pct`;
2. limpeza da base, com remoção de outliers;
3. remoção de valores nulos, iguais a zero ou negativos;
4. logaritmização dos valores válidos de `renda_med_pct`;
5. uso da camada de centroides dos setores censitários previamente disponível;
6. criação do envoltório convexo dos pontos válidos;
7. geração de buffer de 1.500 metros;
8. ajuste do semivariograma no Smart-Map/QGIS;
9. inserção manual dos parâmetros no SAGA GIS 2.1.2;
10. execução da krigagem ordinária local;
11. exportação da superfície krigada raster em formato GeoTIFF no SAGA GIS;

12. recorte da superfície krigada raster pela máscara espacial do buffer;
13. extração dos valores da superfície krigada raster para os pontos dos imóveis/anúncios OMI;
14. criação da coluna **renda_krigada_ln** na base de imóveis;
15. integração do resultado final às camadas municipais em **saida**.

5.1.5 Extração dos valores krigados para os imóveis

A superfície krigada raster não foi utilizada apenas como produto de interpolação. As superfícies krigadas raster foram exportadas pelo SAGA GIS em formato GeoTIFF antes das etapas de recorte e integração com a base de imóveis.

Após sua geração e recorte pelo buffer, os valores interpolados foram associados espacialmente aos pontos da base de imóveis/anúncios OMI. Para cada imóvel, foi extraído o valor da célula ou posição correspondente da superfície krigada raster.

Esse valor foi incorporado à base final como a coluna:

renda_krigada_ln

A coluna foi mantida em escala logarítmica. Portanto, o produto final não corresponde à renda em escala original, mas ao valor interpolado de **renda_med_pct** após logaritimização.

Essa etapa permitiu transformar a superfície interpolada em um atributo tabular associado a cada imóvel, viabilizando análises posteriores que relacionem os anúncios OMI aos valores estimados de renda no entorno de sua localização.

2.6. Validação

Foram realizadas validações visuais das superfícies krigadas por meio da sobreposição das superfícies geradas sobre imagens de satélite dos municípios.

Essa validação teve caráter exploratório e permitiu avaliar a coerência espacial geral dos resultados interpolados em relação à configuração territorial observada visualmente.

Além da validação visual, também foi utilizado o cálculo da significância como procedimento de validação dos ajustes realizados, em conjunto com os demais parâmetros documentados dos semivariogramas. A significância foi definida pela razão entre o efeito pepita e o patamar do ajuste. Considerou-se aceitável a significância no intervalo de 0,15 a 0,30, buscando-se manter esse valor o mais próximo possível de 0,15.

5.1.6 Resultados

O processo resultou em superfícies krigadas raster em GeoTIFF para os municípios selecionados dos Lotes 1 e 2 e em camadas municipais de imóveis/anúncios OMI com a renda krigada incorporada como atributo.

Os três produtos principais foram:

1. superfície krigada raster de renda exportada em GeoTIFF;
2. superfície krigada raster recortada pelo buffer;
3. base de imóveis/anúncios OMI com a coluna `renda_krigada_ln`, consolidada em `dna_estimacao_consolidado_renda_krigada`.

5.1.6.1 Parâmetros finais dos semivariogramas

Município	Lote	Modelo	Efeito pepita (C0)	Patamar (C0+C)	Al- cance	Distância máxima	Lag
belo_hori- zonte	1	esférico	0.113	0.556	4278.831	6000	250
campo_grande	1	gaussi- ano	0.085	0.366	5832.829	6000	400
fortaleza	1	exponen- cial	0.109	0.419	5716.310	6000	250
porto_ve- lho	1	esférico	0.059	0.285	4324.974	4500	371.389
cuiaba	2	exponen- cial	0.072	0.479	5555.004	7200	400
curitiba	2	gaussi- ano	0.116	0.482	8896.143	9000	250.748
manaus	2	exponen- cial	0.073	0.467	6587.048	8000	229.627
salvador	2	exponen- cial	0.092	0.475	3926.684	5500	161.020

Fonte: `documentacao_variogramas_krigagem\01_tabela_parametros\tabela_parametros_krigagem_final`

5.1.6.2 Ajustes dos semivariogramas

Além da tabela de parâmetros finais, foram inseridos no relatório os prints dos semivariogramas ajustados no Smart-Map/QGIS. Essas imagens funcionam como evidência visual complementar

dos modelos adotados e permitem conferir graficamente os ajustes realizados antes da inserção manual dos parâmetros no SAGA GIS 2.1.2.

5.1.6.2.1 Belo Horizonte

Modelo adotado: esférico.

Efeito pepita (C_0): 0.113.

Patamar (C_0+C): 0.556.

Alcance: 4278.831 m.

Distância máxima: 6000 m.

Lag: 250 m.




Figura 5.1: Semivariograma ajustado — Belo Horizonte




Figura 5.2: Layout da superfície krigada — Belo Horizonte

5.1.6.2.2 Campo Grande

Modelo adotado: gaussiano.

Efeito pepita (C0): 0.085.

Patamar (C0+C): 0.366.

Alcance: 5832.829 m.

Distância máxima: 6000 m.
Lag: 400 m.




Figura 5.3: Semivariograma ajustado — Campo Grande




Figura 5.4: Layout da superfície krigada — Campo Grande

5.1.6.2.3 Fortaleza

Modelo adotado: exponencial.

Efeito pepita (C0): 0.109.

Patamar (C0+C): 0.419.

Alcance: 5716.310 m.

Distância máxima: 6000 m.
Lag: 250 m.




Figura 5.5: Semivariograma ajustado — Fortaleza




Figura 5.6: Layout da superfície krigada — Fortaleza

5.1.6.2.4 Porto Velho

Modelo adotado: esférico.

Efeito pepita (C0): 0.059.

Patamar (C0+C): 0.285.

Alcance: 4324.974 m.

Distância máxima: 4500 m.
Lag: 371.389 m.




Figura 5.7: Semivariograma ajustado — Porto Velho




Figura 5.8: Layout da superfície krigada — Porto Velho

5.1.6.2.5 Cuiabá

Modelo adotado: exponencial.

Efeito pepita (C0): 0.072.

Patamar (C0+C): 0.479.

Alcance: 5555.004 m.

Distância máxima: 7200 m.
Lag: 400 m.




Figura 5.9: Semivariograma ajustado — Cuiabá




Figura 5.10: Layout da superfície krigada — Cuiabá

5.1.6.2.6 Curitiba

Modelo adotado: gaussiano.

Efeito pepita (C0): 0.116.

Patamar (C0+C): 0.482.

Alcance: 8896.143 m.

Distância máxima: 9000 m.
Lag: 250.748 m.




Figura 5.11: Semivariograma ajustado — Curitiba




Figura 5.12: Layout da superfície krigada — Curitiba

5.1.6.2.7 Manaus

Modelo adotado: exponencial.

Efeito pepita (C0): 0.073.

Patamar (C0+C): 0.467.

Alcance: 6587.048 m.

Distância máxima: 8000 m.
Lag: 229.627 m.




Figura 5.13: Semivariograma ajustado — Manaus




Figura 5.14: Layout da superfície krigada — Manaus

5.1.6.2.8 Salvador

Modelo adotado: exponencial.

Efeito pepita (C0): 0.092.

Patamar (C0+C): 0.475.

Alcance: 3926.684 m.

Distância máxima: 5500 m.
Lag: 161.020 m.




Figura 5.15: Semivariograma ajustado — Salvador




Figura 5.16: Layout da superfície krigada — Salvador

5.1.7 Síntese dos resultados

O produto final efetivo do processo corresponde às bases municipais de imóveis/anúncios OMI com uma nova coluna de renda krigada, denominada `renda_krigada_ln`, em escala logarítmica, consolidada em `dna_estimacao_consolidado_renda_krigada`.

Essa coluna foi obtida a partir da extração dos valores das superfícies krigadas raster geradas por krigagem ordinária local e exportadas em GeoTIFF no SAGA GIS. As superfícies foram ajustadas a partir dos centroides dos setores censitários, com base na variável geográfica `renda_med_pct`, previamente limpa e logaritmizada.

As superfícies krigadas foram recortadas pelo buffer de 1.500 metros construído ao redor do envoltório convexo dos pontos válidos e avaliadas visualmente por sobreposição a imagens de satélite dos municípios.

5.2 Valor Unitário do metro quadrado edificado

Conforme já explicitado no segundo capítulo, o método adotado neste projeto para a avaliação em massa dos imóveis é o **método evolutivo**. Assim, neste projeto, os dados coletados de imóveis edificados são utilizados de maneira secundária (ou auxiliar), de maneira que ajudem a explicar o fenômeno da *localização*.

5.2.1 Modelo Linear

Para a obtenção da variável `VUM2` inicialmente é ajustado um modelo de regressão linear múltipla para descrever o comportamento do mercado imobiliário de casas e apartamentos.

(CONTINUA)

5.2.2 Geração da superfície de valores unitários de metro quadrado construído

Após o ajuste do modelo de mínimos quadrados ordinários, os dados da amostra utilizados para o ajuste do modelo foram homogeneizados de acordo com fatores de homogeneização estimados diretamente do modelo. Por exemplo, para a variável área, foi derivado o fator área, conforme a Equação 5.1:

$$F_{\text{Área}} = \left(\frac{A_{\text{imóvel}}}{100} \right)^{-0,25} \quad (5.1)$$

Veja Note 2 para entender como é feita a derivação racional de fatores de homogeneização.

Após o procedimento de homogeneização, foi gerada uma superfície de valores de metro quadrado construído com os dados homogeneizados através do algoritmo IDW (*inverse distance weighting*).

i Nota 1: Inverse Distance Weighting

Segundo DRUCK et al. (2004, p. 83), “uma alternativa simples para gerar uma superfície bidimensional” consiste em ajustar uma função bidimensional sobre as amostras, prevendo valores em uma grade ($\hat{z}_i$), com a seguinte formulação:

$$\hat{z}_i = \frac{\sum_{j=1}^n w_{ij} z_j}{\sum_{j=1}^n w_{ij}} \quad (5.2)$$

Em que:

- z_j é o valor da cota (VU) de uma amostra vizinha do ponto i da grade;
- w_{ij} é um fator de ponderação.

Com base neste esquema básico supra-mencionado, é possível gerar vários interpoladores (vizinho mais próximo, média simples ou média ponderada). A ponderação mais usada consiste em adotar pesos que variam com o inverso de uma potência k da distância euclidiana do ponto da amostra ao ponto da grade em que se deseja prever valores (d_{ij}), assim:

$$w_{ij} = \frac{1}{d_{ij}^k} \quad (5.3)$$

Em que: - $d_{ij} = \sqrt{(x_i - x_j)^2 + (y_i - y_j)^2}$

i Nota 2: Derivação Racional de Fatores

A derivação racional de fatores de homogeneização é feita de acordo com os coeficientes estimados em um modelo de regressão linear múltipla (RLM).

Os fatores serão aditivos quando o modelo RLM for ajustado na escala de preços unitários (PU), ou serão multiplicativos quando o modelo RLM for ajustado com a transformação da variável dependente para a escala logaritmica, o que é usual na Engenharia de Avaliações. Para entender, basta perceber que, para um modelo ajustado na escala logaritmica, tem-se:

$$\log(\widehat{PU}) = \hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k \quad (5.4)$$

Efetuada a exponenciação em ambos os lados de Equação 5.4, tem-se:

$$\widehat{PU} = \exp(\hat{\beta}_0 + \hat{\beta}_1 x_1 + \dots + \hat{\beta}_k x_k) \quad (5.5)$$

Como a exponencial da soma é o produto das exponenciais, a Equação 5.5 torna-se:

$$\widehat{PU} = \exp(\hat{\beta}_0) \cdot \exp(\hat{\beta}_1 x_1) \cdot \dots \cdot \exp(\hat{\beta}_k x_k) \quad (5.6)$$

Donde entende-se o motivo dos fatores derivados com este modelo serem multiplicativos, pois, deste modelo, deduz-se:

$$F_1 = \exp(\hat{\beta}_1 x_1); F_2 = \exp(\hat{\beta}_2 x_2); \dots; F_k = \exp(\hat{\beta}_k x_k)$$

5.3 Clusters de localização

Tendo em vista a heterogeneidade espacial dos dados, em adição aos níveis espaciais “Distritos” e “Setores censitários”, foram gerados *clusters* espaciais para cada tipo de imóvel e para cada município com base no método de agrupamento não supervisionado *k-means*. As variáveis de entrada para a clusterização foram as coordenadas geográficas (*lat*, *lon*) padronizadas.

Para tanto, as tipologias imobiliárias foram reclassificadas a partir das tipologias presentes na base de dados, de acordo com a Tabela 5.1.

Tabela 5.1: Reclassificação das tipologias imobiliárias para geração dos clusters espaciais. Elaboração própria.

Classificação da base de dados	Reclassificação
Apartamento	Apartamento
Cobertura	Apartamento
Flat	Apartamento
Casa	Casa
Casa de Condomínio	Casa
Casa de vila	Casa
Sobrado	Casa
Lote/Terreno	Lote

O número de *clusters* (k) por cidade foi controlado, de modo a ser um número inteiro no intervalo $3 \leq k \leq 30$, na dependência do número de observações por município (n). Nesse sentido, k foi calculado conforme Equação 5.7:

$$k = 3 + 3 \cdot \log_{10} n \quad (5.7)$$

Sendo:

$$k = \max(k, 3) \quad (5.8)$$

e

$$k = \min(k, 30) \quad (5.9)$$

A Tabela 5.2 identifica o número de clusters gerado por tipologia e município.

Tabela 5.2: Número de clusters gerado por tipologia e município. Elaboração própria.

Lote	Município	k Apartamento	k Casa	k Lote
1	Porto Velho	12	12	9
	Fortaleza	16	15	11
	Belo Horizonte	18	16	13
	Campo Grande	13	14	11
2	Manaus	14	14	12
	Salvador	17	16	10
	Rio de Janeiro	19	16	13
	Curitiba	17	16	15
	Cuiabá.	14	14	11

5.4 Variáveis de localização – Acessibilidade e Centralidade

Em complemento às variáveis de localização procedentes do grupo de trabalho “Cartografia e variáveis”, foram geradas as variáveis de localização *Acessibilidade* e *Centralidade*. Estas são fundadas na abordagem da configuração espacial urbana, a qual se baseia em análises de redes. Nessa perspectiva, a representação fundamental de um sistema espacial é um grafo que inclui as unidades de espaço público (trechos de vias) e suas conexões com espaços adjacentes (trechos vizinhos) (KRAFTA; RAUBER, 2020). A exploração das propriedades das redes espaciais urbanas levou ao desenvolvimento de uma série de medidas configuracionais, dentre as quais as duas adotadas neste trabalho.

A configuração espacial se relaciona diretamente com o valor imobiliário, uma vez que a geração de espaços mais ou menos acessíveis ou centrais está ligada à facilitação ou obstrução de interações entre indivíduos e a seu acesso aos benefícios e oportunidades urbanas BATTY (2013).

5.4.1 Acessibilidade (Ace)

A acessibilidade refere-se à proximidade ou facilidade de acesso de uma localização em relação ao conjunto de localizações urbanas HANSEN (1959), refletindo a vantagem locacional do espaço. Por essa razão, localizações mais acessíveis tendem a traduzir-se em valores imobiliários

superiores (MORALES et al., 2020; CHEN et al., 2023). A medida é calculada mensurando-se o quão próximo um trecho viário está de todos os outros trechos do sistema, conforme Equação 5.10:

$$Ace_i = \sum_{i \neq j, j: d_{ij} \leq 7000} \frac{W_j}{d_{ij}} \quad (5.10)$$

Em que, W_j é a carga do trecho de destino do movimento, e d_{ij} é a extensão do caminho mínimo (menor distância) pela rede entre o trecho de origem, i , e o trecho de destino j , tendo em vista o raio limite de busca de 7000 metros. Tanto para a acessibilidade como para a centralidade a carga é a população residente no trecho, presumindo-se que localizações são mais acessíveis não apenas pela configuração geométrica da rede, mas também na proporção em que são potenciais focos de origem ou destino de indivíduos.

5.4.2 Centralidade (Cen)

A centralidade mensura a capacidade de intermediação, verificando a recorrência com que um trecho viário pertence ao caminho mínimo entre todos os pares de pontos componentes da rede. Desse modo, a centralidade relaciona-se diretamente à probabilidade de que o trecho seja escolhido em deslocamentos urbanos e, por extensão, ao movimento. Assim, por um lado, valores altos de centralidade se associam a valores do solo ou imobiliários superiores (MORALES et al., 2020; RAHMAN et al., 2021), posto que estas vias conferem vantagem de acesso a vias arteriais. Além disso, maior movimento implica em superior competitividade por usos do solo que dependam de maior visibilidade (comércio e serviços), o que pode impactar positivamente no valor para outros usos. Por outro lado, essas vias podem ser associadas a externalidades negativas de movimento (congestionamento, ruídos, poluição etc.), o que teria efeitos marginais negativos sobre os valores de imóveis (HEYMAN; SOMMERVOLL, 2019; WANG; CHEN, 2020).

Dentre as muitas versões possíveis de centralidade, neste trabalho adota-se uma medida de *centralidade gravitacional*, calculada em duas etapas, conforme Equação 5.11:

$$Cen = EB_k \cdot GF_k \quad (5.11)$$

EB_k corresponde a uma medida “*edge betweenness*”, a qual calcula o número de caminhos mínimos entre i e j que passam pelo trecho de referência k :

$$EB_k = \sum_{i \neq j} \frac{\sigma_{ij}(k)}{\sigma_{ij}} \quad (5.12)$$

Em que, $\sigma_{ij}(k)$ corresponde ao número de caminhos mínimos entre os trechos i e j que passam por k , e σ_{ij} corresponde ao total de caminhos mínimos entre i e j . Em outras palavras, o trecho possui alto valor de EB quando muitos caminhos mínimos o perpassam, funcionando como um corredor importante de circulação.

GF_k é o “fator gravitacional”, isto é, o quão relevante é cada trecho em termos de polarização do movimento, dada suas capacidades de origem e destino em função da população. A medida é calculada como:

$$GF_k = \sum_{j: d_{ij} \leq 7000} \frac{W_i W_j}{d_{ij}} \quad (5.13)$$

Em que, W_i e W_j correspondem à população dos trechos de origem e de destino, respectivamente, e d_{ij} é a extensão do caminho mínimo entre i e j , tendo em vista o raio limite de busca de 7000 metros.

Adotou-se raio limite de 7000 metros com o duplo objetivo de otimizar o processamento dos cálculos e porque XIAO (2017), corroborado por AGUILAR (2026), entendem que esse raio se correlaciona ao movimento macroescalar urbano (automobilístico) em maior medida que o raio global. Adicionalmente, também para otimizar o desempenho dos cálculos, apenas para GF_k limitou-se o raio de busca, dado que uma EB_k limitada exigiria recalcular caminhos mínimos para muitos subconjuntos da rede.

A rede viária foi modelada como um grafo primal não direcionado, em que vértices representam interseções viárias e arestas representam trechos. O comprimento destes foi utilizado como peso para as arestas. A população associada aos trechos foi previamente estimada a partir da divisão da população dos setores censitários (INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE), 2023) pelos trechos incidentes em cada setor. Como os cálculos são efetuados sobre os vértices, e não sobre as arestas, a população de cada vértice foi estimada como a média da população de cada aresta a ele relacionada.

Para os cálculos foram empregados, no R, os pacotes `sfnetworks` para a conversão da rede viária em uma estrutura de rede espacial, e `igraph`, utilizado para conversão da rede em grafos.

As medidas foram posteriormente normalizadas para o intervalo $[0, 1]$, utilizando o percentil acumulado (*percent rank*). Como a centralidade exibe distribuição potencial, com forte assimetria positiva, aplicou-se previamente à normalização a transformação $\ln(\text{Cen} + 1)$.

6 Análise de dados com modelos de aprendizado de máquina

7 Análise de dados de lotes urbanos

Os dados de lotes urbanos foram analisados a partir de modelos de regressão linear generalizada, seguido de krigagem ordinária dos resíduos, resultando num modelo final de regressão linear ordinária com os resíduos krigados como variável explicativa. Nas seções abaixo esse procedimento é detalhado.

7.1 Modelo Linear Hierárquico (MLH)

Antes do ajuste dos modelos previsores foi necessário o tratamento de variáveis. Merece destaque o fato de que a distância ao litoral (“dist_litoral”) somente foi calculada para municípios costeiros, possuindo valores ausentes nos demais contextos. Para lidar com esse inconveniente, foi incluída a variável dicotômica “litorâneo” (1 = município costeiro; 0 = município interiorano) e os valores ausentes de “dist_litoral” (todos com “litorâneo” = 0) foram substituídos por 0.

Em seguida foi ajustado um modelo linear hierárquico (MLH, pacote *lme4*) condicionado à verificação de multicolinearidade, a partir dos valores de *Variance Inflation Factor* (VIF). O MLH captura a relação entre variáveis explicativas (efeitos fixos) e a variável explicada, considerando a estrutura hierárquica dos dados por meio de efeitos aleatórios, neste trabalho definidos a partir de agrupamentos espaciais (RAUDENBUSH, 2002). Foram empregados como níveis hierárquicos os municípios (“cd_mun”), os *clusters* de localização para lotes (“cluster”), e os setores censitários (“cd_setor”). A especificação do MLH é:

```
MLH <- lmer(log(valor_unitario) ~ log(area/450) + log(dist_cbd_m/100) +  
  classe_declividade + log1p(dist_litoral_cond/100) + litoraneo +  
  impermeab + log1p(d_demo_h_km2_setor) + log1p(dens_eq_saud_setor) +  
  rend_med_pct_sm_setor + sqrt(var_ren_med_setor) + ace + cen +  
  VUM2 + log1p(altura_media_muni_500m) + ndvi_media +  
  log1p(ndbi_media) + log1p(ui_media) + bci_media_media_setor +  
  (1 | cluster) + (1 | cd_mun) + (1 | cd_setor),  
  data = Lote8)
```

A definição das variáveis consta no Quadro 1.

Quadro 1. Definição das variáveis empregadas nos modelos. Elaboração própria.

Variável	Definição
<i>valor_unitario</i>	Valor unitário do lote, obtido pela razão entre o valor absoluto registrado no anúncio e a área.
<i>area/450</i>	Área do lote homogeneizada (dividida pela área do lote padrão, estipulada em 450 m ²).
<i>dist_cbd_m/100</i>	Distância ao centro principal (dividida por 100).
<i>classe_declividade</i>	Classe de declividade do terreno, variando de 1 (plano) a 6 (escarpado).
<i>dist_litoral_cond/100</i>	Distância ao litoral condicionada a municípios costeiros (dividida por 100).
<i>litoraneo</i>	Variável dicotômica para municípios costeiros.
<i>impermeab</i>	Percentagem de solo impermeabilizado no setor censitário.
<i>d_demo_h_km2_setor</i>	Densidade demográfica (hab/km ²) do setor censitário.
<i>dens_eq_saude_setor</i>	Densidade de equipamentos de saúde (n/km ²) do setor censitário.
<i>rend_med_pct_sm_setor</i>	Renda per capita média em salários mínimos do setor censitário
<i>var_ren_med_setor</i>	Variância da renda média do chefe do domicílio, por setor censitário.
<i>ace</i>	Acessibilidade.
<i>cen</i>	Centralidade.
<i>VUM2</i>	Valor do m ² edificado, estimado a partir do modelo com imóveis edificados.

Variável	Definição
<i>altura_media_muni_500m</i>	Altura média das edificações em raio de 500 m a partir da observação.
<i>ndvi_media</i>	Índice de vegetação diferenciada normalizada média em raio de 500 m a partir da observação.
<i>ndbi_media</i>	Índice de áreas construídas por diferença normalizada em raio de 500 m a partir da observação.
<i>ui_media</i>	Índice de urbanização em raio de 500 m a partir da observação.
<i>bci_media</i>	Índice de composição biofísica em raio de 500 m a partir da observação.

Foram sucessivamente removidas as variáveis com maiores valores (para $VIF \geq 10$) e coeficientes menos significativos, o que resultou na exclusão de *ndbi_media* ($VIF = 145,1532$; $t = -0,809$), *rndsi_media* ($VIF = 50,6742$; $t = 2,742$) e *ui_media* ($VIF = 191,4915$; $t = -3,014$).

As Tabelas 7.1, 7.2 e 7.3 exibem os resultados do modelo definitivo empregado.

Tabela 7.1: Modelo linear hierárquico para lotes das capitais dos Lotes 1 e 2. Elaboração própria.

Efeitos fixos	Estimativa	Erro-padrão	Valor-t	VIF
Intercepto	5,9880	0,2216	27,7170	/
log(area/450)	-0,3116	0,0042	-73,663	1,0175
log(dist_cbd_m/100)	-0,0352	0,0221	-1,5950	1,8089
classe_declividade	-0,0150	0,0052	-2,8800	1,0314
log1p(dist_litoral_cond/100)	-0,0466	0,0191	-2,4390	1,1828
litoraneo	0,6687	0,2765	2,4180	1,0994
impermeab	0,0019	0,0007	2,5980	2,1173
log1p(d_demo_h_km2_setor)	-0,0438	0,0105	-4,1640	1,7830
log1p(dens_eq_saud_setor)	0,0281	0,0046	6,1670	1,1548
rend_med_pct_sm_setor	0,1601	0,0104	15,3880	2,4180
sqrt(var_ren_med_setor)	-1,799e-06	1,062e-06	-1,6940	1,3523
ace	0,1768	0,0563	3,1400	2,0417

Efeitos fixos	Estimativa	Erro-padrão	Valor-t	VIF
cen	0,2960	0,0371	7,9770.	1,2631
I(VUM2/4870)	0,6442	0,0386	16,6790	1,9282
log1p(altura_me- dia_muni_500m)	0,3223	0,0354	9,1110	1,7466
ndvi_media	-0,6657	0,0809	-8,2310	1,8428
bci_media	0,6146	0,2334	2,633	1,2803

Tabela 7.2: Estatísticas de qualidade de ajuste para o modelo MLH. Elaboração própria.

Estatística	Valor
R^2 condicional (efeitos fixos e aleatórios)	0,8990
R^2 marginal (efeitos fixos)	0,3780
AIC	5491,5660

Tabela 7.3: Variância dos efeitos aleatórios. Elaboração própria.

Nível	Var.
Município	0,1357
Cluster	0,0323
Setor	0,1050
Residual.	0,0527

Foi efetuada análise dos resíduos, indicando que existe desvio da distribuição teórica ($D = 0,0710$; $p < 2,2e - 16$), mas ele é muito pequeno, o que é normal, diante do grande número de observações. Existe dispersão de 4,61% ($p < 2,2e - 16$), acima do esperado, porém o valor é pequeno e não preocupante. Por fim, revelou-se 0,30% de outliers ($p < 2,2e - 16$), cifra plausível para quase 15 mil observações em nove cidades.

Além do R^2 e do AIC, o ajuste do modelo foi avaliado por meio das métricas *Raiz do Erro Quadrático Médio* (**RMSE**) e *Erro Percentual Absoluto Médio* (**MAPE**), que apresentaram valores de 578,46 e 0,1529, respectivamente. O **RMSE** indica que, em média, as estimativas apresentam desvios da ordem de R\$ 578,46 em relação aos valores observados, enquanto o **MAPE** indica um erro percentual absoluto médio de aproximadamente 15,3%. A Tabela 7.4 demonstra essas métricas segregadas por município:

Tabela 7.4: RMSE e MAPE por município dos Lotes 1 e 2. Elaboração própria.

Município	RMSE	MAPE	n
Manaus	1901,00	0,184	516
Cuiabá	352,00	0,176	349
Curitiba	474,00	0,158	8818
Salvador	519,00	0,151	212
Rio de Janeiro	434,00	0,142	1450
Fortaleza	299,00	0,141	503
Belo Horizonte	504,00	0,131	1408
Porto Velho	104,00	0,129	80
Campo Grande	121,00	0,127	444

Nota-se que embora o município com maior erro (Manaus) apresente raiz do erro quadrático médio de R\$ 1901,00, em termos de erro percentual absoluto médio esse valor é inferior a 20%, cifra considerada aceitável para o fim de avaliação em massa e em sintonia com a literatura ([OLIVEIRA et al., 2022](#); [PROVÍNCIA DE CÓRDOBA, 2025](#)).

7.2 Homogeneização

7.3 Geração da superfície de valores unitários de lotes

7.4 Modelo final

8 Equações de Estimação

9 Equações de Estimação

10 Classificação de Municípios

11 Conclusão

Neste caderno mostrou-se ...

Referências

- AGUILAR, R. L. **Capital socioespacial e valorização imobiliária: uma análise baseada em modelos hedônicos de preços em Porto Alegre (RS)**, 2026. tese de doutorado, Porto Alegre/RS: Universidade Federal do Rio Grande do Sul.
- BATTY, M. **The New Science of Cities**. MIT Press, 2013.
- CHEN, Y.; JIAO, J.; FARAH, A. Disparities in affecting factors of housing price: A machine learning approach to the effects of housing status, public transit, and density factors on single-family housing price. **Cities**, v. 140, p. 104432, 2023. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0264275123002445>>.
- DAVIES, P. L.; GATHER, U. Breakdown Point — Examples and Counterexamples. **REVSTAT-Statistical Journal**, p. 1–17 Pages, 2007. REVSTAT-Statistical Journal. Disponível em: <<https://revstat.ine.pt/index.php/REVSTAT/article/view/39>>. Acesso em: 26/5/2026.
- DONOHU, D. L.; HUBER, P. J. The notion of breakdown point. In: P. J. Bickel; K. A. Doksum; J. L. Hodges (Org.); **A Festschrift for Erich L. Lehmann**. p.157–184, 1983. Belmont, CA: Wadsworth.
- DRUCK, S.; CARVALHO, M. S.; CÂMARA, G.; MONTEIRO, A. M. V. (ORG.). **Análise Espacial de Dados Geográficos**. Planaltina, DF: Embrapa Cerrados, 2004.
- EDGEWORTH, F. Y. On Observations Relating to Several Quantities. **Hermathena**, v. 6, n. 13, p. 279–285, 1887. Trinity College Dublin. Disponível em: <<http://www.jstor.org/stable/23036355>>. Acesso em: 26/5/2026.
- GONZALEZ, J. D.; YOHAI, V. J.; ZAMAR, R. H. Robust Clustering Using Tau-Scales., 2019. Disponível em: <<https://arxiv.org/abs/1906.08198>>.
- HAMPEL, F. R. A General Qualitative Definition of Robustness. **The Annals of Mathematical Statistics**, v. 42, n. 6, p. 1887–1896, 1971. Institute of Mathematical Statistics. Disponível em: <<http://www.jstor.org/stable/2240114>>. Acesso em: 26/5/2026.
- HANSEN, W. G. How Accessibility Shapes Land Use. **Journal of the American Institute of Planners**, v. 25, n. 2, p. 73–76, 1959. Routledge. Disponível em: <<https://doi.org/10.1080/01944365908978307>>.
- HEYMAN, A. V.; SOMMERVOLL, D. E. House prices and relative location. **Cities**, v. 95, p. 102373, 2019. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0264275118312241>>.
- HODGES, J. L. Efficiency in normal samples and tolerance of extreme values for some estimates of location., 1967. Disponível em: <<https://api.semanticscholar.org/CorpusID:120840555>>.
- HUBER, P. J. Robust Estimation of a Location Parameter. **The Annals of Mathematical Statistics**, v. 35, n. 1, p. 73–101, 1964. Disponível em: <<https://doi.org/10.1214/aoms/117>>.

7703732>.

INSTITUTO BRASILEIRO DE GEOGRAFIA E ESTATÍSTICA (IBGE). Censo 2022: Agregados por Setores Censitários preliminares: população e domicílios., 2023. online. Disponível em: <<https://www.ibge.gov.br/estatisticas/sociais/populacao/22827-censo-demografico-2022.html?edicao=39499/&t=resultados>>.

KRAFTA, R.; RAUBER, A. Morfologia Urbana e a revolução dos dados. **Revista de Morfologia Urbana**, v. 8, n. 1, p. e00151, 2020. Disponível em: <<https://revistademorfologiaurbana.org/index.php/rmu/article/view/151>>.

MORALES, J.; STEIN, A.; FLACKE, J.; ZEVENBERGEN, J. Predictive land value modelling in Guatemala City using a geostatistical approach and Space Syntax. **International Journal of Geographical Information Science**, v. 34, n. 7, p. 1451–1474, 2020. Taylor & Francis. Disponível em: <<https://doi.org/10.1080/13658816.2020.1725014>>.

OLIVEIRA, A. A. F. DE; BANDEIRA, S. R. V.; SILVA, C. V. A. Estimativa de desempenho de métodos de aprendizado de máquina baseados em árvores de decisão na valoração do solo no município de Fortaleza, Brasil. **Revista Valorem**, v. 1, n. 1, p. 1–15, 2022. Disponível em: <<https://revistavalorem.com/index.php/home/article/view/8>>.

PROVÍNCIA DE CÓRDOBA. Informe Estudio del mercado de la tierra urbana de la Provincia de Córdoba 2025., 2025. Córdoba: IDECOR.

RAHMAN, MD. M.; HOSSAIN, T.; CHOWDHURY, MD. R. H.; UDDIN, M. S. Effects of Transportation Accessibility on Residential Housing Rent: Evidence from Metropolitan City of Khulna, Bangladesh. **Journal of Urban Planning and Development**, v. 147, n. 2, p. 04021009, 2021. Disponível em: <<https://ascelibrary.org/doi/abs/10.1061/%28ASCE%29UP.1943-5444.0000668>>.

RAUDENBUSH, A. S., S. W.; Bryk. **Hierarchical Linear Models: Applications and Data Analysis Methods**. 2^o ed. Thousand Oaks: Sage Publications, 2002.

ROUSSEEUW, P. J. Least Median of Squares Regression. **Journal of the American Statistical Association**, v. 79, n. 388, p. 871–880, 1984. [American Statistical Association, Taylor & Francis, Ltd.]. Disponível em: <<http://www.jstor.org/stable/2288718>>. Acesso em: 5/3/2026.

ROUSSEEUW, P. J.; RUTS, I.; TUKEY, J. W. The Bagplot: A Bivariate Boxplot. **The American Statistician**, v. 53, n. 4, p. 382–387, 1999. Taylor & Francis. Disponível em: <<https://doi.org/10.1080/00031305.1999.10474494>>.

SILVA, E. DA; RAMOS DA SILVA, L.; VIEIRA, C. A. O.; OLIVEIRA, F. H. Avaliação Em Massa e Imposto Predial Em Itabira, Brasil. **Mercado Imobiliário e Imposto Predial: Aplicações de Técnicas de Avaliação Em Massa**, 2024. Banco Interamericano de Desenvolvimento. Divisão de Gestão Fiscal: Huáscar Eguino; Diego Erba.

STRUYF, A.; ROUSSEEUW, P. J. High-Dimensional Computation of the Deepest Location. **Computational Statistics & Data Analysis**, v. 34, n. 4, p. 415–426, 2000. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0167947399001127>>.

TUKEY, J. W. Mathematics and the Picturing of Data., 1975. Disponível em: <<https://api.semanticscholar.org/CorpusID:233506359>>.

WANG, C.-H.; CHEN, N. A geographically weighted regression approach to investigating local built-environment effects on home prices in the housing downturn, recovery, and subsequent

increases. **Journal of Housing and the Built Environment**, v. 35, n. 4, p. 1283–1302, 2020. Springer. Disponível em: <<http://www.jstor.org/stable/45378909>>. Acesso em: 3/7/2026.

XIAO, Y. **Urban morphology and housing market**. New York: Springer, 2017.

YOHAI, V. J. High Breakdown-Point and High Efficiency Robust Estimates for Regression. **The Annals of Statistics**, v. 15, n. 2, p. 642–656, 1987. Institute of Mathematical Statistics. Disponível em: <<https://www.jstor.org/stable/2241331>>. Acesso em: 18/5/2026.

A Apêndice 1: Scripts