

Caderno Metodológico

Etapas de Modelagem e Avaliação em Massa

Equipe UFSC

junho, 2026

Índice

Apresentação	3
1 Introdução	4
2 Metodologia Geral	5
3 Limpeza dos dados	6
3.1 Métodos de limpeza de dados	6
3.1.1 <i>Breakdown point</i>	8
3.1.2 Mínimos Quadrados Ordinários	9
3.1.3 <i>M-Estimadores</i>	10
3.1.4 Mínimos Quadrados Aparados	11
3.1.5 <i>MM-estimadores</i>	13
4 Métodos de classificação	15
4.1 <i>K-means</i>	15
4.2 <i>K-TAU</i>	15
4.3 <i>K-medoids</i>	18
5 Análise de dados dos imóveis edificadas	19
6 Conclusão	20
Referências	21
Apêndices	22
A Apêndice 1: Scripts	22

Apresentação

Trata-se de um caderno metodológico para o projeto do Valor de Referência do Cadastro Imobiliário Brasileiro (CIB)

1 Introdução

Neste caderno ...

2 Metodologia Geral

Para o projeto do Valor de Referência (VR) do Cadastro Imobiliário Brasileiro (CIB) foi adotado o método evolutivo, da **ME**:

3 Limpeza dos dados

A Etapa de Modelagem e Avaliações em Massa é iniciada com a limpeza dos dados oriundos do Observatório do Mercado Imobiliário. Neste capítulo são apresentados os métodos utilizados.

3.1 Métodos de limpeza de dados

A limpeza de um conjunto de dados para fins de posterior ajuste de modelos estatísticas pode ser feita com a utilização de diversos métodos. São bem difundidos especialmente os métodos univariados de identificação de *outliers*, como o clássico método de *Chauvenet*, que presume a presença de distribuição normal. Outros métodos univariados, por outro lado, são preferíveis pois prescindem da verificação da hipótese da normalidade e também são considerados mais robustos, como o método do *boxplot*, que classifica como *outliers* aqueles pontos que se encontram a uma distância de $1,5 \cdot \text{IQR}$ dos primeiro e terceiro quartis (Q_1 e Q_3)¹. A Figura 3.1 ilustra graficamente o critério do *boxplot* para identificação de *outliers*:

Neste projeto, porém, optou-se pela utilização de métodos multivariados para a limpeza dos conjuntos de dados, tal como o método dos mínimos quadrados aparados. Tal método foi escolhido com o intuito de evitar a remoção desnecessária de muitos falsos *outliers* da amostra. Para entender, considere-se os *bagplots* (ou diagramas de saco) das Figuras 3.2 e 3.3².

Na Figura 3.2 podem ser vistos os diagramas de caixa de cada variável, às margens do gráfico principal, em que é possível notar uma assimetria na amostra: existe uma série de pontos à direita da distribuição de ambas as variáveis classificados como *outliers* pelo critério do *boxplot* ($Q_3 + 1,5 \cdot \text{IQR}$). O gráfico *bagplot* da Figura 3.2, no entanto, em que 50% dos dados se encontram dentro do primeiro *bag*, de cor mais escura, e cuja área que separa os *outliers* dos *inliers* é exibida em cor cinza-clara, mostra que apenas 4 pontos foram classificados como *outliers*. Note-se ainda que dois dos pontos classificados como *outliers* pelo critério do *bagplot* não foram identificados pelo critério do *boxplot*.

Já na Figura 3.3, em que as variáveis explicativas apresentam distribuição mais simétrica, pois as variáveis encontram-se transformadas para a obtenção da normalidade, pode-se notar que o critério dos *boxplots* implicaria remover uma série de pontos em ambos os lados da distribuição

¹Lembrando que IQR é a medida de dispersão denominada de intervalo interquartil, *i.e.* $\text{IQR} = Q_3 - Q_1$.

²O *bagplot* é uma generalização do *boxplot* para duas dimensões, proposto por ROUSSEEUW et al. (1999), baseado nos conceitos de Profundidade de Tukey, ou Profundidade do meio-espaço e na mediana profunda, ou mediana bivariada (TUKEY, 1975).




Figura 3.1: Boxplot.

das variáveis, enquanto o critério do *bagplot* mostra que, novamente, apenas alguns pontos precisam de fato ser removidos da amostra para uma boa modelagem.




Figura 3.2: Bagplot. Preços Totais

Os conceitos de profundidade estatística e mediana profunda podem ser estendidos para outras dimensões. O algoritmo para o cômputo eficiente destas estatísticas pode ser visto em STRUYF; ROUSSEEUW (2000).

O método dos mínimos quadrados aparados, como veremos na próxima seção, ajusta um modelo de regressão robusta a aproximadamente 50% dos pontos mais “importantes” da amostra, classificando como potenciais *outliers* os pontos que apresentam resíduos padronizados maiores, em módulo, a 2,5, calculados em relação ao modelo ajustado com esses dados mais “importantes”.

3.1.1 Breakdown point

Segundo DAVIES; GATHER (2007), uma das melhores medidas de robustez é o *breakdown point* (ϵ^*), conceito desenvolvido por HODGES (1967) e estendido por HAMPEL (1971) e DONOHO; HUBER (1983):

The breakdown point is one of the most popular measures of robustness of a statistical procedure. Originally introduced for location functionals (Hampel, 1968,




Figura 3.3: Bagplot. Preços Unitários.

1971) the concept has been generalized to scale, regression and — with more or less success — to other situations.

Grosso modo, o *breakdown point* de um estimador é o menor percentual de dados contaminantes que levam o estimador a assumir arbitrariamente grandes valores, ou valores aberrantes. Para compreender, tome-se o caso da estimação da tendência central, μ , de um conjunto de dados com distribuição supostamente normal. A média aritmética, $\bar{x}$, neste caso, é um estimador com $\epsilon^* = 0$, pois basta um dado amostral contaminante para produzir estimativas totalmente equivocadas para o parâmetro. No outro extremo encontra-se a mediana amostral, $\tilde{x}$, apresenta $\epsilon^* = 0,5$, ou seja, a mediana é um estimador robusto para o parâmetro central da distribuição, desde que menos de 50% dos dados amostrais sejam contaminantes.

3.1.2 Mínimos Quadrados Ordinários

Para melhor compreensão do método dos mínimos quadrados aparados, deve-se contextualizá-lo com o método clássico dos mínimos quadrados ordinários.

Seja então o modelo usual de regressão da Equação 3.1, em que $\mathbf{y}$ é um vetor que contém uma **variável dependente** a ser explicada; $\mathbf{X}$ uma matriz que contém em suas colunas uma ou mais **variáveis explicativas**; e β é um vetor de coeficientes a ser estimado.

$$\mathbf{y} = \mathbf{X}\beta + \mathbf{r} \quad (3.1)$$

Então o método dos mínimos quadrados ordinários consiste na minimização de uma função objetivo, S , neste caso a função soma do quadrado dos resíduos, $S(\beta) = \sum r_i^2(\beta)$. Ou seja, no método dos mínimos quadrados ordinários busca-se minimizar:

$$\hat{\beta}_{\text{OLS}} = \min S(\beta) = \arg \min_{\beta} \sum_{i=1}^n r_i^2(\beta) \quad (3.2)$$

Em que $\mathbf{r}$ é um vetor dos resíduos do modelo da Equação 3.1, ou seja:

$$\mathbf{r} = \mathbf{y} - \mathbf{X}\beta \quad (3.3)$$

Assim, a Equação 3.2 poderia ser escrita, de uma maneira mais formal, em notação matricial, como abaixo:

$$= \arg \min_{\beta} \sum_{i=1}^n (\mathbf{y} - \mathbf{X}\beta)^2 \quad (3.4)$$

Deste ponto em diante, contudo, para fins de simplificação do entendimento, adota-se a seguinte notação, reescrevendo a Equação 3.2:

$$\hat{\beta}_{\text{OLS}} = \arg \min_{\beta} \sum_{i=1}^n r_i^2 \quad (3.5)$$

3.1.3 *M-Estimadores*

Os métodos robustos consistem em variações em torno do processo de minimização dos resíduos. Enquanto no método clássico dos mínimos quadrados ordinários é minimizada a soma do quadrado dos resíduos, no método dos mínimos resíduos absolutos, proposto por EDGEWORTH (1887), baseado no método gráfico de Boscovich, tem-se:

$$\hat{\beta}_{\text{LAD}} = \arg \min_{\beta} \sum_{i=1}^n |r_i| \quad (3.6)$$

Segundo ROUSSEEUW (1984), o próximo passo no progresso dos métodos de regressão robustos se deu com o surgimento dos *M-Estimadores*, baseados na ideia da aplicação de uma função, ρ , dos resíduos, diferente da função quadrática, como ilustrado na Equação 3.7.

$$\hat{\beta}_{\text{RLS}} = \arg \min_{\beta} \sum_{i=1}^n \rho(r_i) \quad (3.7)$$

É fácil perceber que a intenção com os *M-Estimadores* foi contornar o fato que a função absoluto, $|r(t)|$, não possui propriedades desejáveis (não é uma função derivável em $t = 0$, o que dificulta o processo de minimização). Assim, HUBER (1964) propôs inicialmente a aplicação da função da Equação 3.8, que consiste em utilizar, para os menores resíduos, em módulo ($|r_i| \leq k$), a função quadrática e, somente a partir de um valor k (ou seja, para $|r_i| > k$), a função absoluto.

$$\rho_{\text{Huber}}(t) = \begin{cases} \frac{1}{2}t^2 & |t| \leq k \\ k|t| - \frac{1}{2}k^2 & |t| > k \end{cases} \quad (3.8)$$

Diversas outras funções foram propostas para a Equação 3.7, como a função *biweight* de Tukey. No entanto, tanto no método dos mínimos desvios absolutos da Equação 3.6, quanto nos *M-Estimadores*, persiste à sensibilidade à presença de *outliers* nas variáveis explicativas, *i.e.*, os *M-Estimadores* são eficazes apenas em lidar com a presença de *outliers* na variável dependente (no caso, imóveis de valores observados muito mais altos ou mais baixos do que os que seria previstos pelo mercado). Desta forma, tanto o estimador MQO da Equação 3.2 como os *M-Estimadores* possuem *breakdown point* $\epsilon^* = 0$.

3.1.4 Mínimos Quadrados Aparados

Então ROUSSEEUW (1984), para contornar o problema dos *outliers* presentes nas variáveis explicativas, propôs dois estimadores robustos alternativos aos *M-Estimadores*: o estimador **LMS** (*Least Median of Squares*), que minimiza **a mediana** dos resíduos quadráticos (Equação 3.9), e o estimador LTS (*Least Trimmed Squares*, ou Mínimos Quadrados Aparados), que minimiza o quadrado dos resíduos, porém apenas para os “bons” pontos da amostra:

$$\beta_{\text{LMS}} = \arg \min_{\beta} \text{med } r_i^2 \quad (3.9)$$

$$\beta_{\text{LTS}} = \min_{\beta} \sum_{i=1}^h (r^2)_{(i)} \quad (3.10)$$

Em que $(r^2)_{(1)} < (r^2)_{(2)} < \dots < (r^2)_{(n)}$ são os resíduos quadráticos ordenados. Resumidamente: o estimador LTS da Equação 3.10 utiliza aproximadamente apenas h pontos da amostra (em geral, $h \approx n/2$) para um ajuste mais estável, e calcula os resíduos de cada ponto da amostra em relação à esta reta de regressão robusta. Após o cálculo dos resíduos os pontos são classificados

como “bons” (pontos cujos resíduos padronizados são menores que 2,5, em módulo) ou “ruins” (pontos cujos resíduos padronizados são maiores ou iguais a 2,5).

O estimador LTS é famoso por apresentar *breakdown point* igual a 50% (máximo)³, isto é, contanto que menos de metade dos pontos do conjunto de dados em análise consista de *outliers*, o algoritmo é eficaz em identificar esses pontos anômalos e ajustar um modelo que reflete o padrão verdadeiro dos dados.

Para ilustrar, o gráfico da Figura 3.4 mostra como a presença de *outliers*, especialmente aqueles dois pontos de maior e menor preço unitário, influenciam a estimação do coeficiente angular do modelo, mostrando um efeito maior (reta vermelha) do que o efeito “real” da variável área sobre os preços unitários (reta verde). Já a Figura 3.5 mostra que o ajuste da reta de regressão linear ordinária apenas aos pontos centrais (*i.e.*, sem a inclusão dos dois pontos extremos supramencionados), seria já suficiente para a obtenção de um modelo bem ajustado.




Figura 3.4

Neste caso, seria fácil estimar um modelo de regressão linear ordinária e identificar os dois pontos extremos e removê-los do modelo, obtendo assim um modelo já mais confiável. No entanto, o estimador LTS ainda classifica como *outliers* outros pontos da amostra, ilustrados em vermelho na Figura 3.6, melhorando assim o ajuste final do modelo.

É importante destacar que não se trata de um processo para exclusão automática de *outliers*, no entanto: a aplicação do algoritmo LTS não dispensa a análise dos pontos classificados

³Quando são utilizados para o ajuste do modelo apenas aproximadamente 50% dos dados, *i.e.*, quando $h = (n/2) + 1$.




Figura 3.5

como *outliers* pelo avaliador, que deve decidir se retira realmente todos os pontos *flagados* pelo algoritmo.

3.1.5 *MM-estimadores*

Os *MM-estimadores* foram primeiramente propostos por YOHAI (1987).

Assim como o estimador de mínimos quadrados aparados, os *MM-estimadores* podem apresentar o valor máximo para o *breakdown-point* (0,5), na condição em que os resíduos tenham distribuição normal (YOHAI, 1987).

Segundo YOHAI (1987), os *MM-estimadores* são obtidos em três estágios. No primeiro, um modelo de regressão robusta com alto *breakdown-point*, como o dos mínimos quadrados aparados, é estimado. Com o modelo obtido no primeiro estágio, então, são computados os resíduos e, com estes, por sua vez, um estimador robusto de escala dos resíduos é obtido.

Neste projeto, o objetivo com a utilização dos métodos robustos é a mera limpeza dos dados, o que possibilita a utilização de outros métodos a posteriori com mais segurança. Portanto, não foi adotada a utilização dos **MM-Estimadores**.




Figura 3.6

4 Métodos de classificação

Para este projeto foram utilizados métodos robustos de classificação (ou *clusterização*). Assim como no caso da regressão robusta, é mais fácil compreender os métodos de classificação robusta quando comparámo-los aos métodos clássicos de classificação, como o método *K-means*.

4.1 *K-means*

O método *K-means* é um método de *clusterização* de dados que consiste na minimização da distância quadrática entre os pontos da amostras e K centros $\mu_1, \mu_2, \dots, \mu_k$. Sejam as distâncias definidas conforme a Equação 4.1 abaixo

$$D(\mathbf{x}_i, \mu_1, \dots, \mu_K) = \min_{1 \leq i \leq K} \|\mathbf{x}_i - \mu_j\|, 1 \leq i, \leq k \quad (4.1)$$

Os centros dos clusters, dessa forma, são obtidos conforme a Equação 4.2:

$$(\hat{\mu}_1, \dots, \hat{\mu}_k) = \arg \min_{\mu_1, \dots, \mu_k} \sum_{i=1}^n D^2(\mathbf{x}_i, \mu_1, \dots, \mu_K) \quad (4.2)$$

O problema com o método *K-means* é que, a exemplo do que ocorre com o método dos mínimos quadrados ordinários, este método é muito sensível à presença de *outliers* (GONZALEZ et al., 2019, p. 2). A Figura 4.1 (A) mostra que o método é eficiente em estimar as k-médias, porém, na presença de *outliers* (Figura 4.1 (B)), os resultados ficam comprometidos.

4.2 *K-TAU*

Driver: GPKG

Available layers:

	layer_name	geometry_type	features	fields
1	face_logradouro	Multi Line String	20329	8
2	logradouro	Multi Line String	14261	8
3	municipio	Multi Polygon	1	15
4	regiao_geografica_imediata	Multi Polygon	1	11






Figura 4.1: Problema com *K-means*: sensibilidade à *outliers*. Fonte: GONZALEZ et al. (2019)

5	regiao_geografica_intermediaria	Multi Polygon	1	9
6	setor_censitario	Multi Polygon	1004	29
7	setor_censitario_urbano	Multi Polygon	930	29
8	subsetor_urbano	Multi Polygon	4360	1
9	uf	Multi Polygon	1	6
10	limite_perimetro_urbano	Multi Polygon	9	12
11	edificacao	Point	258267	6
12	amostra_omi	Point	83869	62
13	variavel_geografica_setor_censitario	Multi Polygon	1004	68
14	variavel_geografica_amostra_omi	Point	83600	121
15	layer_styles	NA	12	12
crs_name				
1	SIRGAS 2000			
2	SIRGAS 2000			
3	SIRGAS 2000			
4	SIRGAS 2000			
5	SIRGAS 2000			
6	SIRGAS 2000			
7	SIRGAS 2000			
8	SIRGAS 2000			
9	SIRGAS 2000			
10	SIRGAS 2000			
11	SIRGAS 2000			

```
12 SIRGAS 2000
13 SIRGAS 2000
14 SIRGAS 2000
15      <NA>
```

```
Reading layer `variavel_geografica_amostra_omi' from data source
  `/Users/droubi/Documents/LabFSG/Caderno_Metodologico/data/4205407_Florianopolis_r007_2026-
04-06.gpkg'
  using driver `GPKG'
Simple feature collection with 83600 features and 121 fields
Geometry type: POINT
Dimension:      XY
Bounding box:   xmin: -48.60608 ymin: -27.81767 xmax: -48.37625 ymax: -27.38705
Geodetic CRS:  SIRGAS 2000
```





GONZALEZ et al. (2019) propuseram

4.3 *K-medoids*

K-medoids é um método robusto de *clusterização* que

5 Análise de dados dos imóveis edificadas

Neste projeto os dados coletados de imóveis edificadas foram utilizados de maneira secundária ou auxiliar, haja vista que o método adotado para a avaliação em massa dos imóveis é o método evolutivo.

6 Conclusão

Neste caderno mostrou-se ...

Referências

- DAVIES, P. L.; GATHER, U. Breakdown Point — Examples and Counterexamples. **REVSTAT-Statistical Journal**, p. 1–17 Pages, 2007. REVSTAT-Statistical Journal. Disponível em: <<https://revstat.ine.pt/index.php/REVSTAT/article/view/39>>. Acesso em: 26/5/2026.
- DONOHU, D. L.; HUBER, P. J. The notion of breakdown point. In: P. J. Bickel; K. A. Doksum; J. L. Hodges (Org.); **A Festschrift for Erich L. Lehmann**. p.157–184, 1983. Belmont, CA: Wadsworth.
- EDGEWORTH, F. Y. On Observations Relating to Several Quantities. **Hermathena**, v. 6, n. 13, p. 279–285, 1887. Trinity College Dublin. Disponível em: <<http://www.jstor.org/stable/23036355>>. Acesso em: 26/5/2026.
- GONZALEZ, J. D.; YOHAI, V. J.; ZAMAR, R. H. Robust Clustering Using Tau-Scales., 2019. Disponível em: <<https://arxiv.org/abs/1906.08198>>.
- HAMPEL, F. R. A General Qualitative Definition of Robustness. **The Annals of Mathematical Statistics**, v. 42, n. 6, p. 1887–1896, 1971. Institute of Mathematical Statistics. Disponível em: <<http://www.jstor.org/stable/2240114>>. Acesso em: 26/5/2026.
- HODGES, J. L. Efficiency in normal samples and tolerance of extreme values for some estimates of location., 1967. Disponível em: <<https://api.semanticscholar.org/CorpusID:120840555>>.
- HUBER, P. J. Robust Estimation of a Location Parameter. **The Annals of Mathematical Statistics**, v. 35, n. 1, p. 73–101, 1964. Disponível em: <<https://doi.org/10.1214/aoms/1177703732>>.
- ROUSSEEUW, P. J. Least Median of Squares Regression. **Journal of the American Statistical Association**, v. 79, n. 388, p. 871–880, 1984. [American Statistical Association, Taylor & Francis, Ltd.]. Disponível em: <<http://www.jstor.org/stable/2288718>>. Acesso em: 5/3/2026.
- ROUSSEEUW, P. J.; RUTS, I.; TUKEY, J. W. The Bagplot: A Bivariate Boxplot. **The American Statistician**, v. 53, n. 4, p. 382–387, 1999. Taylor & Francis. Disponível em: <<https://doi.org/10.1080/00031305.1999.10474494>>.
- STRUYF, A.; ROUSSEEUW, P. J. High-Dimensional Computation of the Deepest Location. **Computational Statistics & Data Analysis**, v. 34, n. 4, p. 415–426, 2000. Disponível em: <<https://www.sciencedirect.com/science/article/pii/S0167947399001127>>.
- TUKEY, J. W. Mathematics and the Picturing of Data., 1975. Disponível em: <<https://api.semanticscholar.org/CorpusID:233506359>>.
- YOHAI, V. J. High Breakdown-Point and High Efficiency Robust Estimates for Regression. **The Annals of Statistics**, v. 15, n. 2, p. 642–656, 1987. Institute of Mathematical Statistics. Disponível em: <<https://www.jstor.org/stable/2241331>>. Acesso em: 18/5/2026.

A Apêndice 1: Scripts